

Kelompok 9

Data Engineering

Anggota kelompok:

- **Christian Caesar - 2802461574**
- **Gerald Amadeo Passover Sutanto - 2802457740**
- **Daniel Putra Tjandrawan - 2802463762**

Dataset info

Name: Retail Store Dataset

Columns : 11 (Transaction ID, Customer ID, Category, Item, Price Per Unit, Quantity, Total Spent, Payment Method, Location, Transaction Date, Discount Applied)

Rows : 12,575

Type : csv

Peran Data Engineering dalam Ekosistem Data

Data engineering memiliki peran penting dalam mengelola alur data agar data dapat digunakan dengan baik untuk kebutuhan bisnis maupun analisis. Data engineer bertugas mengumpulkan data dari berbagai sumber, membersihkan data, melakukan transformasi, lalu menyimpannya ke dalam sistem seperti data warehouse atau data lake. Data engineering menjadi penghubung antara sumber data dan pengguna data seperti data analyst, data scientist, maupun business intelligence.

Contoh Peran Data Engineering pada Dataset Retail Store Sales

- Menggabungkan data transaksi penjualan ke dalam satu dataset.
- Membersihkan data kosong atau data duplikat.
- Mengubah format tanggal transaksi agar bisa dianalisis sebagai time series.
- Menyiapkan data kategori produk dan total sales untuk dashboard penjualan.
- Memastikan data siap digunakan untuk analisis trend dan visualisasi

Data Architecture & Pipeline Components

Data architecture dan data pipeline membantu proses alur data dari sumber hingga siap digunakan untuk analisis. Pada dataset retail store sales, data transaksi berasal dari file CSV, lalu diproses dengan membersihkan data, mengubah format tanggal, dan menyimpan data untuk kebutuhan dashboard atau visualisasi.

Komponen Pipeline

- **Data Source** → file retail_store_sales.csv
- **Data Processing** → cleaning dan transformasi data
- **Data Storage** → database atau data warehouse
- **Visualization** → dashboard dan analisis penjualan

ETL vs ELT

ETL (Extract, Transform, Load) adalah proses data yang dibersihkan dan diubah terlebih dahulu sebelum disimpan ke database. Sedangkan ELT (Extract, Load, Transform) menyimpan data terlebih dahulu lalu diproses di dalam sistem penyimpanan.

Pada dataset retail store sales, contoh ETL adalah membersihkan data transaksi dan mengubah format tanggal sebelum dimasukkan ke database. Sedangkan ELT cocok digunakan jika data penjualan sangat besar dan diproses langsung di cloud storage atau data warehouse.

Tool Selection Based on Business Needs

Pemilihan tools dalam data engineering juga harus disesuaikan dengan kebutuhan bisnis, jumlah data, dan tujuan analisis. Tools yang digunakan harus mampu membantu proses pengolahan data menjadi lebih cepat dan efisien.


Pada dataset retail store sales, Pentaho digunakan untuk proses ETL seperti mengambil data dari file CSV, membersihkan data, melakukan transformasi, dan memindahkan data ke database. Penggunaan Pentaho membantu proses pengolahan data menjadi lebih otomatis dan terstruktur sebelum digunakan untuk analisis atau dashboard.

Data Quality & Reliability


Data quality adalah proses memastikan data akurat, konsisten, lengkap, dan valid sebelum digunakan untuk analisis. Sedangkan data reliability berkaitan dengan kepercayaan terhadap data agar hasil analisis tetap stabil dan tidak menghasilkan informasi yang salah.

Pada dataset retail store sales, data perlu dicek untuk memastikan tidak ada data kosong, duplikat, atau kesalahan format tanggal dan angka. Proses cleaning dan validasi dilakukan agar dashboard dan hasil analisis penjualan lebih akurat dan dapat dipercaya.

Transformation




Data modeling/Star schema





Job orchestration



Retail Store Dashboard

1.55M

Total Revenue

11.971K

Total Transactions


66K

Total Quantity


129.77

Average Revenue


Revenue by Category




Revenue by Payment Method




Revenue by location




Revenue by Month and Year



Count of transaction by discount



Average of price by category



Thankyou